

## Ayudantía 9 - Mat044

---

17 de noviembre de 2021

## Distribución Normal

Considerando una muestra aleatoria de tamaño  $n$  de  $X_i$  donde  $X_i \sim^{iid} N(\mu, \sigma^2)$ , como son *iid* se puede escribir también en la forma multivarada  $X = (X_1, \dots, X_n) \sim N_n(\mu, \sigma^2 I_n)$ .

Entonces, al considerar la suma de los  $X_i$  se tiene que

$$X = \sum X_i \Rightarrow E(X) = E\left(\sum X_i\right) = \sum E(X_i) = n\mu$$

Luego, al considerar  $X = \frac{1}{n} \sum X_i$  se tiene que

$$E(X) = \mu$$

Finalmente, si se tiene una muestra de tamaño  $n$  de una normal (iid) se tiene que el promedio aritmético de los datos es una v.a. y además tiene esperanza  $\mu$ .

Si  $E(\bar{x}) = \mu$ , ¿Qué ocurre con su varianza?

Como la muestra es independiente,  $X_i \perp X_j \forall i \neq j$  entonces se tiene que  $V(X_i + X_j) = V(X_i) + V(X_j)$ . Además, la varianza es función cuadrática, por lo tanto

$$V(\alpha x) = \alpha^2 V(x)$$

De este modo,

$$V(\bar{x}) = V\left(\frac{1}{n} \sum X_i\right) = \frac{1}{n^2} \sum V(X_i) = \frac{1}{n^2} \sum \sigma^2 = \frac{\sigma^2}{n}$$

Por lo tanto, se tiene que si  $X_i \sim^{iid} N(\mu, \sigma^2)$  es una muestra aleatoria, entonces  $\bar{X}$  es una variable aleatoria y además tenemos que

$$\bar{X} \sim N(\mu, \sigma^2/n).$$

Entonces se tienen las siguientes características:

- **Insesgado** : La esperanza del estimador es el parámetro a estimar:  $E(\bar{x}) = \mu$
- **Consistente** :  $\lim_{n \rightarrow \infty} \bar{X} = \mu \forall \epsilon > 0 \lim_{n \rightarrow \infty} P(|\bar{x}_n - \mu| > \epsilon) = 0$

Esto último quiere decir, que a medida que el tamaño de la muestra  $n$  crece  $\bar{x}$  'converge' a un valor determinístico , ' $\lim_{n \rightarrow \infty} \bar{x}_n \sim N(\mu, 0)$ '.

## Estimación: método de momentos

Para una muestra  $X_1, \dots, X_n$  que sigue un modelo estadístico  $\{P_\theta^n : \theta \in \Theta\}$  se tiene el estimador de momentos como:

$$m_k = \frac{1}{n} \sum x_i^k$$

donde  $m_k = \hat{\mu}_k$  k-ésimo momento empírico.

Considerando la siguiente muestra aleatoria:

$i$	$X_i$	$i$	$X_i$
1	172,45	11	141,14
2	141,93	12	71,19
3	146,82	13	83,39
4	172,66	14	128,33
5	96,94	15	90,82
6	100,20	16	94,37
7	161,51	17	124,05
8	104,76	18	120,68
9	128,06	19	110,60
10	156,38	20	125,34

Si se desea obtener los parámetros de interés de la media y desviación estándar  $\mu$  y  $\sigma$ , si los datos provienen de una normal entonces:

$$\mu = \int x f(x; \theta) dx$$

$$\sigma^2 = \int (x - \mu)^2 f(x; \theta) dx$$

Entonces, se tiene el estimador de momentos para  $\mu$  (es el primer momento)

$$m_1 = \frac{1}{n} \sum x_i = 114,37$$

luego, para obtener el estimador de momentos para :

$$\sigma^2 = V(X) = E(X^2) - E(X)^2 = \mu_2 - \mu_1^2$$

$$\sigma = \sqrt{\mu_2 - \mu_1^2}$$

$$\hat{\sigma}_{MM} = \sqrt{m_2 - m_1^2}$$

$$\begin{aligned}
 m_2 - m_1^2 &= \frac{1}{n} \sum x_i^2 - \left( \frac{1}{n} \sum x_i \right)^2 = \frac{1}{n} \left( \sum x_i^2 - \frac{1}{n} (n\bar{x})^2 \right) \\
 &= \frac{1}{n} \left( \sum x_i^2 - n\bar{x}^2 \right) = \frac{1}{n} \sum (x_i - \bar{x})^2
 \end{aligned}$$

entonces, se tiene que

$$\hat{\sigma}_{MM} = \sqrt{\frac{1}{n} \sum (x_i - \bar{x})^2}$$

donde para la muestra se tiene que

$$\sum (x_i - \bar{x})^2 = 22734,86$$

por lo tanto

$$\hat{\sigma}_{MM} = 33,72$$

## Estimación máximo verosimil

Considerando una muestra aleatoria  $x_i$  iid con función de probabilidad  $f(\cdot)$  la cual pertenece a un modelo estadístico  $P_\theta = \{f(\cdot|\theta), \theta \in \Theta\}$  de manera que  $f(\cdot) = f(\cdot|\theta_0)$  donde  $\theta_0$  es el parámetro real de donde provienen los datos.

Se desea inferir el parámetro  $\hat{\theta}$  tal que sea lo más cercano posible al valor real  $\theta_0$  a través de la muestra  $x_i$ .

Se tiene la densidad conjunto de la uestra:

$$L(\theta_0|x_1, \dots, x_n) = f(x_1, \dots, x_n|\theta_0) = \prod_i f(x_i|\theta_0)$$

pues la muestra es independiente, donde  $L(\theta_0|x_i)$  se llama función de verosimilitud (likelihood)

Considerando la función de verosimilitud:

$$L(\theta|x_i) = \prod_i f(x_i|\theta)$$

se busca el parámetro  $\hat{\theta}$  tal que maximice la probabilidad de obtener dicha muestra, entonces se tiene el estimador máximo verosímil (MLE):

$$\hat{\theta}_{MLE} \in \arg \max_{\theta \in \Theta} L(\theta|x_i)$$

Como  $L(\theta)$  es una productoria, se tiene  $\ln(L) = \sum \ln(f(\theta|x_i))$ , como  $\ln$  es una función monótona creciente se tiene que

$$\hat{\theta}_{MLE} \in \arg \max_{\theta \in \Theta} L(\theta|x_i) \iff \hat{\theta}_{MLE} \in \arg \max_{\theta \in \Theta} \ln(L(\theta|x_i))$$

por lo que es más fácil trabajar con la log-verosimilitud:

$$\ell(\theta) = \ln(L(\theta))$$

entonces el método se reduce a encontrar el parámetro  $\hat{\theta}$  tal que maximice la log-verosimilitud (o verosimilitud a conveniencia).



Considerando una muestra aleatoria desde una  $N(\mu, \sigma^2)$ , la verosimilitud:

$$L(\mu, \sigma^2; x) = (2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right\}$$

considerando la log-verosimilitud

$$\ell(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

entonces, para maximizar verosimilitud se tiene que :

$$\frac{\partial \ell}{\partial \mu}(\mu, \sigma^2) = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0$$

$$\frac{\partial \ell}{\partial \sigma^2}(\mu, \sigma^2) = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 = 0$$

y se tiene que el máximo se alcanza en:

$$\hat{\mu}_{ML} = \bar{x}, \quad \hat{\sigma}_{ML}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu}_{ML})^2$$

Volviendo al caso inicial con los estimadores de momentos, se tiene el estimador ML para  $\sigma^2$  pero por una propiedad de invarianza, se tiene que el MLE para  $\sigma$  sería  $\sqrt{\hat{\sigma}_{ML}^2}$ , entonces, para una muestra aleatoria que proviene de una distribución normal, el estimador ML coincide con el estimador de momentos.

Considerando  $X_1, \dots, X_n$  una muestra de v.a. IID desde una  $U[0, \theta]$ . Esto es,

$$f(x; \theta) = \begin{cases} \frac{1}{\theta}, & 0 \leq x \leq \theta \\ 0, & \text{en otro caso} \end{cases} = \frac{1}{\theta} I_{[0, \theta]}(x_i) =, \quad \theta > 0$$

de esta forma

$$L(\theta; x) = \frac{1}{\theta^n} \prod_{i=1}^n I_{[0, \theta]}(x_i) = \frac{1}{\theta^n} \prod_{i=1}^n I_{[x_i, \infty)}(\theta)$$

entonces, queremos encontrar el máximo de la verosimilitud

$$\prod_{i=1}^n I_{[x_i, \infty)}(\theta) = 1 \iff I_{[x_i, \infty)}(\theta) = 1 \quad \forall i \iff x_i \leq \theta \quad \forall i$$

esto es,  $\max_i \{x_i\} \leq \theta \iff I_{[x_i, \infty)}(\theta) = 1$ . Luego, se tiene que

$$L(\theta; x) = \frac{1}{\theta^n} I_{[\max_i x_i, \infty)}(\theta)$$

entonces

$$\hat{\theta}_{ML} = \max_i \{x_i\}$$

Si (2.85, 1.51, 0.69, 0.57, 2.29) es una muestra de una  $U[0, \theta]$  entonces  $\hat{\theta}_{ML} = 2.85$